

Otimização do Algoritmo ClonalG para Agrupamento de Dados

Busca Local Contínua, Diversidade e Mutação Adaptativa

Marcos Daniel e Vinicius Macedo

Instituto Federal do Norte de Minas Gerais

Julho de 2026

O Problema

- **Agrupamento de Dados (Clustering):** Divisão não supervisionada de dados multidimensionais em subgrupos homogêneos.
- **Desafios dos Métodos Clássicos (k-Means):**
 - Dependência crítica da inicialização de centroides (risco de mínimos locais).
 - Necessidade de definir o número de clusters k previamente.
- **O Desafio do ClonalG Básico (Lab 2):**
 - **Mutação Rígida:** Centróides limitados a pontos exatos do dataset (busca puramente combinatória/estrutural).
 - **Perda de Diversidade:** Pressão seletiva puramente gananciosa (só pela afinidade), levando a população a convergir rapidamente para o mesmo mínimo local redundante.

A Solução Adotada

Objetivo Principal

Unir a busca global robusta do algoritmo imunológico com a precisão da busca contínua local e a manutenção de nichos de busca distintos.

- 1 **Afinidade por Silhouette:** Uso do Índice Silhouette como critério principal de qualidade dos agrupamentos.
- 2 **Mutação Estrutural Dinâmica de k :** Adiciona ou remove centroides de forma adaptativa.
- 3 **Hipermutação Paramétrica (Novo):** Adição de perturbação gaussiana contínua para refinamento espacial fino.
- 4 **Decaimento Temporal da Mutação (Novo):** A intensidade da mutação diminui ao longo das gerações.
- 5 **Seleção por Diversidade na Memória (Novo):** Ponderação explícita que penaliza anticorpos redundantes e preserva variedade.

Pseudocódigo do ClonalG Otimizado

Entrada: dados X , candidatos de k , tamanho da população N ,
 ρ , β , taxa de seleção, taxa de substituição,
número de iterações

Para cada valor inicial de k :

 Criar população inicial de anticorpos

 Calcular afinidade inicial por Silhouette

 Separar memória e repertório

 Para cada iteração:

 Calcular fator de decaimento temporal da mutação

 Selecionar os melhores anticorpos da memória

 Para cada anticorpo selecionado:

 Gerar clones proporcionalmente à afinidade

 Aplicar hipermutação estrutural e paramétrica com decaimento

 Calcular afinidade dos clones

 Combinar memória, repertório e clones

 Manter os melhores na memória usando afinidade + diversidade

 Substituir parte dos piores indivíduos por novos anticorpos

 Guardar o melhor resultado obtido

Comparar o melhor ClonalG com o k -Médias usando o mesmo k final.

Hipermutação Paramétrica

- A cada clone gerado, além da variação estrutural de k , adicionamos perturbação gaussiana às posições dos centroides:

$$C_i \leftarrow C_i + \mathcal{N}(0, \sigma^2 \cdot I)$$

- O desvio padrão σ decai conforme a afinidade normalizada A_{norm} e o tempo de evolução $d(t)$:

$$\sigma = \text{scale} \times d(t) \times e^{-\rho \cdot A_{\text{norm}}}$$

- **Intuição Biológica/Computacional:**
 - *Anticorpos de alta afinidade* sofrem mutações muito pequenas (busca local fina / exploitation).
 - *Anticorpos de baixa afinidade* sofrem perturbações maiores (exploração espacial / exploration).
 - *Gerações finais* reduzem a perturbação para estabilizar os melhores centroides encontrados.

Afinidade e Decaimento

- **Métrica Silhouette:**

- Mede coesão interna e separação externa; quanto maior, melhor.
- É a função de afinidade usada para selecionar, clonar e manter os melhores anticorpos.
- Permite comparar diretamente o ClonalG com o k-Médias usando o mesmo critério de validação.

- **Dcaimento temporal da mutação:**

$$d(t) = \max \left(0.05, 1 - \frac{t}{T} \right)$$

No início a busca explora mais; no final a mutação fica limitada a ajustes finos.

Seleção Guiada por Diversidade

- Mapeamento de Distância entre Anticorpos (a e b):

$$D(a, b) = \frac{1}{2} \left(\text{mean}_i \min_j d(a_i, b_j) + \text{mean}_j \min_i d(a_i, b_j) \right)$$

Garante um cálculo simétrico de distância mesmo para anticorpos com números diferentes de centroides (k).

- Critério de Seleção Combinado:

$$\text{Score} = A_{\text{norm}} + w_{\text{div}} \times \text{Diversity}_{\text{norm}}$$

- Resultado:

- Impede a proliferação excessiva de cópias quase idênticas na Memória Imunológica (A_{bm}).
- Mantém múltiplos caminhos evolucionários (diferentes valores de k e posições de cluster) ativos simultaneamente.

Metodologia Experimental

Config.	N	ρ	β	Subst.	Sel.	Interpretação
C1	15	2.0	15.0	0.10	0.85	Menor diversidade e seleção alta
C2	15	2.0	5.0	0.30	0.50	Menos clones e mais substituição
C3	30	2.0	15.0	0.30	0.30	População maior e seleção restrita
C4	60	3.5	30.0	0.40	0.60	Busca mais intensa e população maior

- Mesmas configurações da versão antiga, agora com **mutação paramétrica** ($scale = 0.05$), **seleção por diversidade** ($w_{div} = 0.15$) e **decaimento temporal** da mutação.
- Avaliação: 5 datasets, $k \in \{2, 3, 4, 5, 6\}$, 3 execuções independentes e 50 iterações por execução.

Resultados

Config.	Média antiga	Média nova	Ganho médio	Maior ganho pontual
C1	0.5271	0.5389	+0.0117	DS2: +0.0491
C2	0.5289	0.5449	+0.0160	DS2: +0.0758
C3	0.5462	0.5475	+0.0013	DS3: +0.0075
C4	0.5463	0.5510	+0.0047	DS2: +0.0222

Tabela: Comparação do Silhouette médio agregado nos 5 datasets.

- O algoritmo novo melhorou a média em **todas as configurações**.
- A melhor média geral foi da **C4 nova**: 0.5510.
- O maior ganho individual ocorreu no **DataSet 2 com C2**: 0.5462 → 0.6220.

Resultados

Dataset	Melhor config.	k final	ClonalG novo	k-Means	Δ
DS1	C1–C4	3	0.6480	0.6480	0.0000
DS2	C4	2	0.6507	0.3589	+0.2918
DS3	C3	6	0.2067	0.2221	-0.0153
DS4	C4	4	0.5903	0.5866	+0.0037
DS5	C1–C4	2	0.6644	0.6644	0.0000

Tabela: Comparação usando o mesmo k final encontrado pelo ClonalG.


- O ClonalG novo empata nos datasets estáveis, supera claramente no DS2 e supera levemente no DS4.
- O DS3 permanece como caso mais difícil: mesmo com a melhoria, o k-Means ainda obteve maior Silhouette.

Resultados

Dataset	Média antiga	Média nova	Ganho	Leitura do resultado
DS1	0.6480	0.6480	0.0000	Estrutura já resolvida pela versão antiga
DS2	0.5870	0.6230	+0.0359	Maior benefício da diversidade e ajuste local
DS3	0.1990	0.2034	+0.0044	Reduziu a perda, mas k-Means ainda ficou acima
DS4	0.5873	0.5891	+0.0018	Ganho pequeno, porém consistente
DS5	0.6644	0.6644	0.0000	Empate estável nas duas versões

- A melhoria não muda os casos já saturados (DS1 e DS5), mas aumenta robustez nos casos mais difíceis.
- No DS2, o ganho médio por dataset foi o mais relevante: **+0.0359**.


Resultados Visivos



Análise do DataSet 2:

- **k-Means (Direita):** Fica preso em um mínimo local artificial, fundindo grupos reais.
- **ClonalG Otimizado (Esquerda):** Separação nítida em dois clusters coerentes.
- A combinação de mutação paramétrica contínua e diversidade populacional evitou a convergência prematura.

Resultados de Convergência



Comportamento da Evolução:

- A afinidade (Índice Silhouette) cresce rapidamente nas primeiras 10 gerações.
- A mutação paramétrica contínua age refinando localmente as soluções, com perturbações menores nas gerações finais.
- A estabilização ocorre de maneira suave, indicando robustez e convergência estável do sistema.

Discussão dos Resultados

- **Superação do k-Means no DS2:**

- O k-Means ficou preso em mínimos locais devido à inicialização. O ClonalG, graças à busca estocástica global e à mutação paramétrica contínua, localizou a separação ótima estável.

- **Impacto da Diversidade:**

- A seleção de memória guiada por diversidade manteve múltiplos candidatos ativos, permitindo encontrar o número correto de clusters mesmo sob geometrias complexas.

- **Busca Contínua vs. Discreta:**

- A busca paramétrica refinou as coordenadas reais dos centroides, gerando limites de decisão mais suaves e aumentando a métrica do Silhouette.

- **Controle Adaptativo da Busca:**

- O decaimento temporal reduz mutações agressivas no fim da execução, concentrando a busca em ajustes finos nos centroides mais promissores.

Configuração Final Executada

Configuração Única — Mesma para todos os 5 datasets

Parâmetro	Valor
Afinidade interna	Silhouette
Anticorpos (N)	80
Clonagem (ρ)	1,2
Beta (β)	25,0
Taxa de substituição	0,55
Taxa de seleção	0,40
Escala de mutação param.	0,12
Peso de diversidade	0,25
Candidatos de k	{2, 3, 4, 5, 6}
Execuções independentes	3
Iterações por execução	150

- Configuração derivada do **sweep de hiperparâmetros** (melhores valores consolidados).
- Cada dataset parte de todos os k candidatos e o ClonalG escolhe o melhor k fitness via mutação estrutural.

Resultados da Configuração Final

Dataset	k final	ClonalG (média)	ClonalG (melhor)	k-Means	Δ
DS1	3	0,6480	0,6480	0,6480	0,0000
DS2	2	0,6572	0,6637	0,3589	+0,2983
DS3	6	0,2235	0,2301	0,2221	+0,0014
DS4	4	0,5905	0,5905	0,5866	+0,0040
DS5	2	0,6644	0,6644	0,6644	0,0000

Tabela: Comparação usando o mesmo k final encontrado pelo ClonalG (afinidade: Silhouette).

- **DS2:** Maior destaque — ClonalG supera k-Means em **+0,2983** de Silhouette, evitando mínimo local grave.
- **DS3:** Configuração final reverteu o déficit anterior e superou levemente o k-Means (**+0,0014**).
- **DS1 e DS5:** Empate estável; estrutura de clusters já é trivialmente separável.

Conclusões

- O algoritmo ClonalG melhorado provou ser uma alternativa robusta e adaptativa ao clássico k-Means.
- As melhorias propostas (busca local contínua via ruído gaussiano adaptativo, decaimento temporal e nichamento por diversidade) sanaram a convergência prematura típica do SIA básico.
- A afinidade por Silhouette manteve o objetivo experimental consistente entre seleção, validação e comparação com o k-Means.
- **Trabalhos Futuros:** Híbrido o ClonalG com pequenos ciclos de Lloyd/k-Means para refinar centroides após a mutação.