

Otimização do Algoritmo ClonalG para Agrupamento de Dados

Busca Local Contínua, Diversidade e Mutação Adaptativa

Marcos Daniel e Vinicius Macedo

Instituto Federal do Norte de Minas Gerais

Julho de 2026

O Problema

- **Agrupamento de Dados (Clustering):** Divisão não supervisionada de dados multidimensionais em subgrupos homogêneos.
- **Desafios dos Métodos Clássicos (k-Means):**
 - Dependência crítica da inicialização de centroides (risco de mínimos locais).
 - Necessidade de definir o número de clusters k previamente.
- **O Desafio do ClonalG Básico (Lab 2):**
 - **Mutação Rígida:** Centróides limitados a pontos exatos do dataset (busca puramente combinatória/estrutural).
 - **Perda de Diversidade:** Pressão seletiva puramente gananciosa (só pela afinidade), levando a população a convergir rapidamente para o mesmo mínimo local redundante.

A Solução Adotada

Objetivo Principal

Unir a busca global robusta do algoritmo imunológico com a precisão da busca contínua local e a manutenção de nichos de busca distintos.

- 1 **Afinidade configurável:** Suporte ao Índice Silhouette e ao Davies-Bouldin como critérios de qualidade dos agrupamentos.
- 2 **Mutação Estrutural Dinâmica de k :** Adiciona ou remove centroides de forma adaptativa.
- 3 **Hipermutação Paramétrica (Novo):** Adição de perturbação gaussiana contínua para refinamento espacial fino.
- 4 **Decaimento Temporal da Mutação (Novo):** A intensidade da mutação diminui ao longo das gerações.
- 5 **Seleção por Diversidade na Memória (Novo):** Ponderação explícita que penaliza anticorpos redundantes e preserva variedade.

Pseudocódigo do ClonalG Otimizado

Entrada: dados X , candidatos de k , tamanho da população N ,
 ρ , β , taxa de seleção, taxa de substituição,
métrica de afinidade, número de iterações

Para cada valor inicial de k :

- Criar população inicial de anticorpos

- Calcular afinidade inicial por Silhouette ou Davies-Bouldin

- Separar memória e repertório

- Para cada iteração:

 - Calcular fator de decaimento temporal da mutação

 - Selecionar os melhores anticorpos da memória

 - Para cada anticorpo selecionado:

 - Gerar clones proporcionalmente à afinidade

 - Aplicar hipermutação estrutural e paramétrica com decaimento

 - Calcular afinidade dos clones

 - Combinar memória, repertório e clones

 - Manter os melhores na memória usando afinidade + diversidade

 - Substituir parte dos piores indivíduos por novos anticorpos

 - Guardar o melhor resultado obtido

Comparar o melhor ClonalG com o k -Médias usando o mesmo k final.

Hipermutação Paramétrica

- A cada clone gerado, além da variação estrutural de k , adicionamos perturbação gaussiana às posições dos centroides:

$$C_i \leftarrow C_i + \mathcal{N}(0, \sigma^2 \cdot I)$$

- O desvio padrão σ decai conforme a afinidade normalizada A_{norm} e o tempo de evolução $d(t)$:

$$\sigma = \text{scale} \times d(t) \times e^{-\rho \cdot A_{\text{norm}}}$$

- **Intuição Biológica/Computacional:**
 - *Anticorpos de alta afinidade* sofrem mutações muito pequenas (busca local fina / exploitation).
 - *Anticorpos de baixa afinidade* sofrem perturbações maiores (exploração espacial / exploration).
 - *Gerações finais* reduzem a perturbação para estabilizar os melhores centroides encontrados.

Afinidade e Decaimento

- **Métrica Silhouette:**

- Mede coesão interna e separação externa; quanto maior, melhor.
- Continua sendo a métrica principal dos experimentos comparativos.

- **Métrica Davies-Bouldin:**

- Mede similaridade média entre cada cluster e seu cluster mais parecido; quanto menor, melhor.
- No código, a afinidade usa o valor negativo: $\text{afinidade} = -DB$, mantendo a regra geral de maximização.

- **Decaimento temporal da mutação:**

$$d(t) = \max\left(0.05, 1 - \frac{t}{T}\right)$$

No início a busca explora mais; no final a mutação fica limitada a ajustes finos.

Seleção Guiada por Diversidade

- Mapeamento de Distância entre Anticorpos (a e b):

$$D(a, b) = \frac{1}{2} \left(\text{mean}_i \min_j d(a_i, b_j) + \text{mean}_j \min_i d(a_i, b_j) \right)$$

Garante um cálculo simétrico de distância mesmo para anticorpos com números diferentes de centroides (k).

- Critério de Seleção Combinado:

$$\text{Score} = A_{\text{norm}} + w_{\text{div}} \times \text{Diversity}_{\text{norm}}$$

- Resultado:

- Impede a proliferação excessiva de cópias quase idênticas na Memória Imunológica (A_{bm}).
- Mantém múltiplos caminhos evolucionários (diferentes valores de k e posições de cluster) ativos simultaneamente.

Metodologia Experimental

Config.	N	ρ	β	Subst.	Sel.	Interpretação
C1	15	2.0	15.0	0.10	0.85	Menor diversidade e seleção alta
C2	15	2.0	5.0	0.30	0.50	Menos clones e mais substituição
C3	30	2.0	15.0	0.30	0.30	População maior e seleção restrita
C4	60	3.5	30.0	0.40	0.60	Busca mais intensa e população maior

- Mesmas configurações da versão antiga, agora com **mutação paramétrica** ($scale = 0.05$), **seleção por diversidade** ($w_{div} = 0.15$) e **decaimento temporal** da mutação.
- Avaliação: 5 datasets, $k \in \{2, 3, 4, 5, 6\}$, 3 execuções independentes e 50 iterações por execução.

Resultados

Config.	Média antiga	Média nova	Ganho médio	Maior ganho pontual
C1	0.5271	0.5389	+0.0117	DS2: +0.0491
C2	0.5289	0.5449	+0.0160	DS2: +0.0758
C3	0.5462	0.5475	+0.0013	DS3: +0.0075
C4	0.5463	0.5510	+0.0047	DS2: +0.0222

Tabela: Comparação do Silhouette médio agregado nos 5 datasets.

- O algoritmo novo melhorou a média em **todas as configurações**.
- A melhor média geral foi da **C4 nova**: 0.5510.
- O maior ganho individual ocorreu no **DataSet 2 com C2**: 0.5462 → 0.6220.

Resultados

Dataset	Melhor config.	k final	ClonalG novo	k-Means	Δ
DS1	C1–C4	3	0.6480	0.6480	0.0000
DS2	C4	2	0.6507	0.3589	+0.2918
DS3	C3	6	0.2067	0.2221	-0.0153
DS4	C4	4	0.5903	0.5866	+0.0037
DS5	C1–C4	2	0.6644	0.6644	0.0000

Tabela: Comparação usando o mesmo k final encontrado pelo ClonalG.


- O ClonalG novo empata nos datasets estáveis, supera claramente no DS2 e supera levemente no DS4.
- O DS3 permanece como caso mais difícil: mesmo com a melhoria, o k-Means ainda obteve maior Silhouette.

Resultados

Dataset	Média antiga	Média nova	Ganho	Leitura do resultado
DS1	0.6480	0.6480	0.0000	Estrutura já resolvida pela versão antiga
DS2	0.5870	0.6230	+0.0359	Maior benefício da diversidade e ajuste local
DS3	0.1990	0.2034	+0.0044	Reduziu a perda, mas k-Means ainda ficou acima
DS4	0.5873	0.5891	+0.0018	Ganho pequeno, porém consistente
DS5	0.6644	0.6644	0.0000	Empate estável nas duas versões

- A melhoria não muda os casos já saturados (DS1 e DS5), mas aumenta robustez nos casos mais difíceis.
- No DS2, o ganho médio por dataset foi o mais relevante: **+0.0359**.


Resultados Visivos



Análise do DataSet 2:

- **k-Means (Direita):** Fica preso em um mínimo local artificial, fundindo grupos reais.
- **ClonalG Otimizado (Esquerda):** Separação nítida em dois clusters coerentes.
- A combinação de mutação paramétrica contínua e diversidade populacional evitou a convergência prematura.

Resultados de Convergência



Comportamento da Evolução:

- A afinidade (Índice Silhouette) cresce rapidamente nas primeiras 10 gerações.
- A mutação paramétrica contínua age refinando localmente as soluções, com perturbações menores nas gerações finais.
- A estabilização ocorre de maneira suave, indicando robustez e convergência estável do sistema.

Discussão dos Resultados

- **Superação do k-Means no DS2:**

- O k-Means ficou preso em mínimos locais devido à inicialização. O ClonalG, graças à busca estocástica global e à mutação paramétrica contínua, localizou a separação ótima estável.

- **Impacto da Diversidade:**

- A seleção de memória guiada por diversidade manteve múltiplos candidatos ativos, permitindo encontrar o número correto de clusters mesmo sob geometrias complexas.

- **Busca Contínua vs. Discreta:**

- A busca paramétrica refinou as coordenadas reais dos centroides, gerando limites de decisão mais suaves e aumentando a métrica do Silhouette.

- **Controle Adaptativo da Busca:**

- O decaimento temporal reduz mutações agressivas no fim da execução, enquanto o suporte ao Davies-Bouldin permite testar outra função objetivo sem alterar o fluxo principal do ClonalG.

Conclusões

- O algoritmo ClonalG melhorado provou ser uma alternativa robusta e adaptativa ao clássico k-Means.
- As melhorias propostas (busca local contínua via ruído gaussiano adaptativo, decaimento temporal e nichamento por diversidade) sanaram a convergência prematura típica do SIA básico.
- O suporte ao Davies-Bouldin tornou a função de afinidade configurável, permitindo comparar objetivos de agrupamento diferentes no mesmo algoritmo.
- **Trabalhos Futuros:** Híbrido o ClonalG com pequenos ciclos de Lloyd/k-Means para refinar centroides após a mutação.