

Otimização do Algoritmo ClonalG para Agrupamento de Dados

Busca Local Contínua e Seleção por Diversidade

Marcos Daniel e Vinicius Macedo

Instituto Federal do Norte de Minas Gerais

Julho de 2026

O Problema

- **Agrupamento de Dados (Clustering):** Divisão não supervisionada de dados multidimensionais em subgrupos homogêneos.
- **Desafios dos Métodos Clássicos (k-Means):**
 - Dependência crítica da inicialização de centroides (risco de mínimos locais).
 - Necessidade de definir o número de clusters k previamente.
- **O Desafio do ClonalG Básico (Lab 2):**
 - **Mutação Rígida:** Centróides limitados a pontos exatos do dataset (busca puramente combinatória/estrutural).
 - **Perda de Diversidade:** Pressão seletiva puramente gananciosa (só pela afinidade), levando a população a convergir rapidamente para o mesmo mínimo local redundante.

A Solução Adotada

Objetivo Principal

Unir a busca global robusta do algoritmo imunológico com a precisão da busca contínua local e a manutenção de nichos de busca distintos.

- 1 **Afinidade baseada no Índice Silhouette:** Avalia qualitativamente a coesão interna e separação externa dos clusters.
- 2 **Mutação Estrutural Dinâmica de k :** Adiciona ou remove centroides de forma adaptativa.
- 3 **Hipermutação Paramétrica (Novo):** Adição de perturbação gaussiana contínua para refinamento espacial fino.
- 4 **Seleção por Diversidade na Memória (Novo):** Ponderação explícita que penaliza anticorpos redundantes e preserva variedade.

Hipermutação Paramétrica

- A cada clone gerado, além da variação estrutural de k , adicionamos perturbação gaussiana às posições dos centroides:

$$C_i \leftarrow C_i + \mathcal{N}(0, \sigma^2 \cdot I)$$

- O desvio padrão σ (escala da mutação) decai exponencialmente conforme a afinidade normalizada A_{norm} do anticorpo:

$$\sigma = \text{scale} \times e^{-\rho \cdot A_{\text{norm}}}$$

- **Intuição Biológica/Computacional:**
 - *Anticorpos de alta afinidade* sofrem mutações muito pequenas (busca local fina / exploitation).
 - *Anticorpos de baixa afinidade* sofrem perturbações maiores (exploração espacial / exploration).

Seleção Guiada por Diversidade

- Mapeamento de Distância entre Anticorpos (a e b):

$$D(a, b) = \frac{1}{2} \left(\text{mean}_i \min_j d(a_i, b_j) + \text{mean}_j \min_i d(a_i, b_j) \right)$$

Garante um cálculo simétrico de distância mesmo para anticorpos com números diferentes de centroides (k).

- Critério de Seleção Combinado:

$$\text{Score} = A_{\text{norm}} + w_{\text{div}} \times \text{Diversity}_{\text{norm}}$$

- Resultado:

- Impede a proliferação excessiva de cópias quase idênticas na Memória Imunológica (A_{bm}).
- Mantém múltiplos caminhos evolucionários (diferentes valores de k e posições de cluster) ativos simultaneamente.

Metodologia Experimental

Configuração dos Parâmetros:

- População (N): 60
- Taxa de seleção ($SelectionRate$): 0.6
- Taxa de substituição ($ReplaceRate$): 0.4
- Escala de ruído ($scale$): 0.05
- Peso da diversidade (w_{div}): 0.15
- Execuções independentes: 3 runs por dataset.

Conjuntos de Dados (Datasets):

- **DS1 e DS5:** Estrutura bem definida bidimensional.
- **DS2:** Alta dispersão e sobreposição de dados.
- **DS3:** Dados quadridimensionais com 6 clusters.
- **DS4:** Estrutura tridimensional.


Resultados

DataSet	k	ClonalG (Melhor)	ClonalG (Média)	k-Means	Δ (Média)
DS1	3	0.6480	0.6480	0.6480	0.0000
DS2	2	0.6539	0.6220	0.3589	+0.2631
DS3	6	0.2143	0.2045	0.2221	-0.0176
DS4	4	0.5905	0.5903	0.5866	+0.0037
DS5	2	0.6644	0.6644	0.6644	0.0000

Tabela: Silhouette médio e melhor em 3 execuções independentes.

- **Destaque no DS2:** O ClonalG otimizado superou o k-Means em **+0.2631** na média de Silhouette.


Resultados Visivos



Análise do DataSet 2:

- **k-Means (Direita):** Fica preso em um mínimo local artificial, fundindo grupos reais.
- **ClonalG Otimizado (Esquerda):** Separação nítida em dois clusters coerentes.
- A combinação de mutação paramétrica contínua e diversidade populacional evitou a convergência prematura.

Resultados de Convergência



Comportamento da Evolução:

- A afinidade (Índice Silhouette) cresce rapidamente nas primeiras 10 gerações.
- A mutação paramétrica contínua age refinando localmente as soluções.
- A estabilização ocorre de maneira suave, indicando robustez e convergência estável do sistema.

Discussão dos Resultados

- **Superação do k-Means no DS2:**

- O k-Means ficou preso em mínimos locais devido à inicialização. O ClonalG, graças à busca estocástica global e à mutação paramétrica contínua, localizou a separação ótima estável.

- **Impacto da Diversidade:**

- A seleção de memória guiada por diversidade manteve múltiplos candidatos ativos, permitindo encontrar o número correto de clusters mesmo sob geometrias complexas.

- **Busca Contínua vs. Discreta:**

- A busca paramétrica refinou as coordenadas reais dos centroides, gerando limites de decisão mais suaves e aumentando a métrica do Silhouette.

Conclusões

- O algoritmo ClonalG melhorado provou ser uma alternativa robusta e adaptativa ao clássico k-Means.
- As melhorias propostas (busca local contínua via ruído gaussiano adaptativo e nichamento por diversidade) sanaram a convergência prematura típica do SIA básico.
- **Trabalhos Futuros:** Testar outras métricas de afinidade além do Silhouette (como Davies-Bouldin) e automatizar o decaimento dinâmico dos hiperparâmetros de mutação ao longo das gerações.